

일본 호텔 검색 프로젝트

S0 관측형 합성 1,000 명 전체 가설 분석 보고서

실제 관측 원본 296 검색 43 세션 vs S0 합성 모형 1,000 세션 6,900 검색

BUNDLE_RUN_TS: 260904_1149

STEP1-STEP2-STEP3: PASS

목차

1. 증강 목적과 데이터 범위
2. S0 1,000 명 증강 방법 한눈에 보기
3. 작업자가 그대로 실행할 수 있는 단계별 증강 절차
4. 합성 SQLite 테이블 구조와 데이터 사전
5. 데이터 계보·품질·재현성 QA
6. 가설 검증

- 6.1 A1 제한적 필터와 결과 없음
- 6.2 A2 지역·검색의도별 결과 없음
- 6.3 B1 결과 0 건 후 후속검색
- 6.4 B2 0 건 경험과 탐색지속성
- 6.5 B3 즉시·세션 최종 회복
- 6.6 H3 재검색 방식별 회복·상세진입

7. 세션 결과 4 개 세그먼트(보조 분석)

8. 종합 판정·해석 한계·다음 단계

1. 증강 목적과 데이터 범위
2. S0 1,000 명 증강 방법 한눈에 보기
3. 작업자가 그대로 실행할 수 있는 단계별 증강 절차
4. 합성 SQLite 테이블 구조와 데이터 사전
5. 데이터 계보·품질·재현성 QA
6. S0 1,000 명 분석 핵심 요약
7. A1·A2: 필터·지역·검색의도 결과
8. B1·B2: 후속검색과 탐색지속성 결과
9. B3: 서로 다른 세 가지 회복 지표
10. 세션 결과 4 개 세그먼트
11. H3: 재검색 전이 유형 결과
12. 해석 한계와 다음 단계

1. 증강 목적과 데이터 범위

원본은 실제 검색 행동의 가설 판단 근거이며, S0 합성 모형은 관측된 구조와 방향을 재현하는지 확인하는 내부 진단 자료다.

합성 표본의 작은 p 값을 실제 사용자 모집단의 근거 강화로 해석하지 않는다.

합성 DB 는 USER 1,000 행, 세션 1,000 개, SEARCH 6,900 행이며 BOOKING 은 0 행이다. BOOKING 을 증강하지 않은 이유는 이번 단계의 승인 가설 A1-A2-B1-B2-B3-H3 가 검색 결과 없음, 후속검색, 회복 및 hotel_click 기준 상세진입까지를 대상으로 하며 예약 완료를 검정 변수로 사용하지 않기 때문이다. 또한 원본 BOOKING 은 36 행으로 표본이 작아, 이 자료만으로 사용자·호텔·객실·숙박기간별 예약확률과 취소·확정 구조를 안정적으로 추정하기 어렵다. 근거가 부족한 상태에서 예약 레코드를 생성하면 임의의 전환율과 검색·클릭→예약 관계를 합성 데이터에 주입하여 실제로 관측되지 않은 예약 효과를 만들어낼 수 있다. 따라서 원본 BOOKING 은 참조 및 관계 무결성 점검에만 사용하고, S0에서는 예약전환 KPI 를 분석 범위에서 제외했다. 향후 예약 가설을 검증하려면 예약 생성 단위, search-click-room 연결 규칙, 숙박기간과 확정·취소 상태, 목표 전환율 및 허용오차를 별도로 승인한 후 독립 단계에서 BOOKING 을 증강해야 한다. A3, 스트레스 세트, S1~S3, 오버샘플링 및 10,000 명 자료도 포함하지 않았다.

2. S0 1,000 명 증강 방법 한눈에 보기

이 절은 승인된 생성 설정과 실제 생성 코드의 구현을 기준으로 작성한다. S0 데이터는 원본 행을 단순 합친 통합 DB 가 아니라, 원본 43 개 검색 세션의 구조를 반복 표집해 만든 별도의 합성 행동 DB 다. HOTEL 과 ROOM 기준정보는 원본에서 그대로 복사하지만 USERSEARCH·SEARCH_FILTER·SEARCH_RESULT·EVENT 는 새 합성 ID 로 구성되며 원본 사용자 89 명, 검색 296 건, 예약 36 건은 합성 DB 에 포함되지 않는다.

구분	승인·실제 적용 내용
시나리오	S0 observed_like / config_version S0_PILOT_V02 / generationversion 02
표집 단위	원본 검색 세션 43 개
목표 규모	합성 사용자 1,000 명, 합성 세션 1,000 개
표집 설계	OBSERVED_BALANCED_SESSION_BOOTSTRAP_43_V02
균등 복제	각 원본 세션을 23 회씩 먼저 배치(43×23=989 세션)
잔여 11 세션	43 개 원본 세션 중 11 개를 비복원 추출해 1 회씩 추가
순서 무작위화	결합한 1,000 개 세션 순서를 NumPy Generator 로 섞음
난수 고정	random_seed=20260903; QA 통과를 위해 seed 를 변경하지 않음
세그먼트 할당	세그먼트 목표 비율을 강제하지 않음(segment_quota_assignment=false)
결과 0 건 종료	immediate_zero_exit_allowed=false; 원본 세션의 검색 흐름을 유지

표 해설 | 핵심은 '43 세션을 모두 23 회 사용하고 11 세션만 한 번 더 사용'하는 균등 부트스트랩이다. seed 를 고정해 같은 선택과 순서를 재현한다.

1. 2.1 행 생성과 키 변환

- USER: 합성 세션마다 합성 사용자 1 명을 만들고 SYN_U 형식의 새 user_id 를 부여한다. 사용자명·이메일은 합성 placeholder 이며 보고용 산출물에는 내보내지 않는다.
- SESSION: 합성 세션마다 SYN_S 형식의 새 session_id 를 부여한다. 사용자와 세션은 1:1 이다.
- SEARCH: 선택한 원본 세션의 검색 순서를 search_time, search_id 로 정렬하고 SYN_Q 형식의 새 search_id 를 부여한다. 세션 내부 검색 간 시간차는 보존하고 합성 기준시각으로 평행 이동한다.
- SEARCH_FILTER: 원본 검색과 1:1 로 복제하며 SYN_F 형식의 search_filter_id 와 새 search_id 로 연결한다.

- SEARCH_RESULT: 각 검색의 result_rank 순서를 유지하고 SYN_R 형식의 새 search_result_id 를 부여한다. hotel_id 와 room_id 는 복사된 기준정보를 참조한다.
- EVENT: 원본 세션 내부 event_at_event_id 순서를 유지하고 합성 기준시각으로 이동한다. SYN_E 형식의 event_id 와 새 user/session/search/filter 키로 치환한다.
- data_origin: 새 행동 테이블 행에는 synthetic_augmentation 을 기록한다. HOTEL_ROOM 은 원본 기준정보를 그대로 복사한다.

2. 2.2 데이터 정제·제외 규칙

대상	처리 규칙	분석 영향
숙박일 역전	checkout_datescheckin_date 인 복제 검색은 원본 전체 정상 숙박기간 풀에서 고정 seed 로 기간을 하나 뽑아 checkout 을 checkin+기간으로 교체	합성 SEARCH 의 역전 0 건. 설정 문구의 '같은 원본 세션'과 실제 구현이 다르므로 제한사항으로 기록
미노출 클릭 상세	새 search_result 에 hotel_id 가 없는 hotel_click 및 hotel_detail_view 이벤트를 제외	합성 DB 미노출 클릭 0 건 hotel_click 만 상세전입 KPI로 사용
예약 이벤트	booking_start, booking_complete, booking_cancel 이벤트를 제외	예약 행동을 분석하지 않음
BOOKING	스키마만 유지하고 행을 생성하지 않음	0 행. 예약전환을 산출 금지
ROOM 해석	물리 객실 재고가 아니라 객실 상품/타입으로 유지	같은 room_id 기간 중복을 자동 오류로 보지 않음
원본 결합 여부	원본 행동 행을 합성 DB 에 합치지 않음	합성 결과는 실제 1,000 명의 관측 결과가 아니라 모형 내부 진단

표 해설 | 원본 품질 문제는 원본에서 고치지 않고 합성 복제 단계에서만 규칙적으로 처리한다. BOOKING 과 예약 이벤트는 S0 분석 범위에서 제외한다.

3. 2.3 생성 후 무결성 및 성능 보조 구조

- SEARCH-SEARCH_FILTER 1:1, SEARCH.total_result_count 합계와 SEARCH_RESULT 행 수 일치, search_id/hotel_id 중복 결과 0 건을 검증했다.
- SEARCH_RESULT 의 hotel_id 와 ROOM 의 hotel_id 일치, hotel_click 호텔의 검색 결과 포함, 0 건 검색의 impression/click/detail 0 건을 검증했다.
- 검색 정렬용 idx_syn_search_session_time(session_id, search_time, search_id), 결과 조회용 idx_syn_result_search_hotel(search_id, hotel_id), 이벤트 조회용 두 인덱스를 추가했다. 인덱스는 데이터 값을 바꾸지 않는다.
- 수정 전 S0 DB 의 SQLite integrity_check=ok 이며 당시 승인 SHA-256 은 db80db7048add9c0c4cb1a985e67a77ae99bef3a30ce32bedb70cc0ee61dc896 이다. 현재 분석·배포용 최종 승인본은 lineage 제거 시간축 보정 DB 이며 SHA-256 은 7d449fab6847730be38fe46ebb6bd6a5b31690cdf38cf4bdbadeaa75edd1ae04 이다.

3. 작업자가 그대로 실행할 수 있는 단계별 증강 절차

아래 절차는 승인된 생성 코드의 실제 동작을 사람이 다시 구현하거나 동일 코드로 재실행할 수 있도록 풀어 쓴 작업 명세다. 이 보고서 보완 과정에서는 생성기를 실행하지 않았다. 재실행 시에는 반드시 새 빈 출력 폴더를 사용하며 승인된 원본 코드 설정의 해시를 먼저 확인한다.

4. 3.1 준비물과 고정값

구분	파일 또는 값	검증 기준
원본 SQLite	travel_data_filtered_complete_2026-09-08_v02_비식별.sqlite	SHA-256 a0cbf893663b99f1a2e4bb8f5e1c202f0a24677baccf01f9e858ff54d955571
생성 코드	02_관측통합성 1000 명_실행기록_260903_1606_01/호텔검색_관측통합성 1000 명_생성코드_260903_1606_01.py	현재 CRLF 파일은 LF 정규화 후 승인 SHA-256 b7e80ea58cc3fa653d9bcafe781a1d0be9f910cd0c5d1bc27ac04a2bddd1cf2a
생성 설정	02_관측통합성 1000 명_실행기록_260903_1606_01/호텔검색_관측통합성 1000 명_생성설정_260903_1606_01.json	LF 정규화 승인 SHA-256 59e588293184a0a9c7c704752a72f276e1e1184660767c77c0179fe4987512
난수	random_seed=20260903	한 번 고정하며 결과를 맞추기 위해 변경하지 않음
목표	n_users=1,000, n_sessions=1,000	사용자 1 명당 세션 1 개
Python 패키지	Python, numpy, pandas, openpyxl, python-docx	생성 핵심은 sqlite3, numpy, pandas

표 해설 | 재현 전에 파일 해시와 seed 를 먼저 고정한다. 하나라도 다르다면 같은 알고리즘이어도 승인 DB 와 바이트행 결과가 달라질 수 있다.

원본 DB 는 SQLite URI mode=ro 와 PRAGMA query_only=ON 으로 열어야 한다. 실행 직전과 직후에 원본 파일의 SHA-256크기수정시각을 비교하여 원본이 바뀌지 않았음을 확인한다.

5. 3.2 실행 전 원본 점검

- 원본 DB 의 USER 89, HOTEL 1,000, ROOM 3,000, SEARCH 296, SEARCH_FILTER 296, SEARCH_RESULT 8,555, EVENT 10,432, BOOKING 36 행을 확인한다.
- PRAGMA integrity_check 결과가 ok 인지 확인한다.
- SEARCH.search_id 와 SEARCH_FILTER.search_id 가 1:1 이고, SEARCH.total_result_count 합계가 SEARCH_RESULT 8,555 행과 일치하는지 확인한다.
- 세션 수가 43 개인지 확인하고, 각 세션 내부 검색을 search_time, search_id 순으로 안정 정렬할 수 있는지 확인한다.
- 원본의 숙박일 역전 9 건과 미노출 클릭 2 건은 원본을 수정하지 않고 합성 복제 과정에서만 아래 규칙으로 처리한다.

6. 3.3 새 SQLite 스키마 생성

새 출력 SQLite 파일을 만들고 원본 sqlite_master 의 CREATE TABLE SQL 을 읽어 USER, HOTEL, ROOM, SEARCH, SEARCH_FILTER, SEARCH_RESULT, EVENT, BOOKING 의 동일 스키마를 생성한다. 이어서 생성 계보 저장용 _generation_metadata(key TEXT PRIMARY KEY, value TEXT)를 추가한다. 출력 파일이 이미 있으면 덮어쓰지 않고 즉시 중단한다.

```
for table in [user, hotel, room, search, search_filter, search_result, event, booking]:
    ddl = source.sqlite_master[table].sql
    destination.execute(ddl)
destination.execute('CREATE TABLE _generation_metadata(key TEXT PRIMARY KEY, value TEXT)')
```

7. 3.4 HOTEL·ROOM 기준정보 복사

HOTEL 1,000 행과 ROOM 3,000 행은 새로 합성하지 않는다. 원본의 모든 컬럼과 값을 그대로 새 DB에 복사한다. 따라서 이 두 테이블은 합성 행동의 참조 기준정보이며, ROOM은 물리 객실 재고가 아닌 객실 상품/타입으로 해석한다.

8. 3.5 43개 원본 세션을 1,000개로 균등 확장

편향이 큰 단순 복원추출 대신 모든 원본 세션을 거의 같은 횟수로 사용한다. 1,000을 43으로 나누면 몫 $q=23$, 나머지 $r=11$ 이다.

```
q, r = divmod(1000, 43) # q=23, r=11
chosen = 각 원본 session_id를 23회씩 배열한 989개 목록
extra = RNG(seed=20260903)로 43개 중 11개를 비복원 추출
chosen = RNG.permutation(chosen + extra) # 최종 1,000개
```

- 각 원본 세션은 최소 23회 사용되고, 선택된 11개 세션만 24회 사용된다.
- 세그먼트 목표 비율은 강제하지 않는다. 결과 세그먼트는 원본 세션 구조를 복제한 결과로 자연스럽게 나온다.
- chosen 배열의 위치 $i(1 \sim 1,000)$ 가 합성 사용자-세션 번호가 된다.

9. 3.6 합성 ID와 기준시간 생성

객체	새 ID 규칙	예시적 형식	관계
사용자	$SYN_U + i$ 4자리	SYN_U0001	합성 세션 1개에 사용자 1명
세션	$SYN_S + i$ 4자리	SYN_S0001	해당 세션의 SEARCH·EVENT에 공통
검색	$SYN_Q + i$ 4자리 + j 3자리	SYN_Q0001_001	세션 내부 j 번째 검색
필터	$SYN_F + i$ 4자리 + j 3자리	SYN_F0001_001	j 번째 검색과 1:1
검색결과	$SYN_R + i$ 4자리 + j 3자리 + k 4자리	SYN_R0001_001_0001	j 번째 검색의 $result_rank$ 순 k 번째
이벤트	$SYN_E + i$ 4자리 + k 5자리	SYN_E0001_00001	세션 내부 $event_at_event_id$ 순 k 번째

표 해설 | 합성 ID는 원본 ID와 충돌하지 않도록 객체별 접두어와 세션-순번을 결합한다. old→new 매핑을 먼저 만든 뒤 자식 테이블의 FK를 치환한다.

합성 세션 i 의 기준시각은 2027-01-01 00:00:00 KST + $\text{floor}(i/4)$ 일 + $(i \bmod 4)$ 분이다. 이 방식은 합성 세션의 기준시각을 결정적으로 분산시킨다.

10. 3.7 SEARCH 시간과 값 복제

6. 선택된 원본 세션의 SEARCH를 $search_time$, $search_id$ 순으로 정렬한다.
7. 원본 세션의 유효한 SEARCH. $search_time$ 과 실제 복제 대상 EVENT. $event_at$ 중 최솟값을 $session_origin$ 으로 둔다. NULL timestamp는 원점 후보에서 제외하고 원본 NULL은 그대로 유지한다.
8. 각 검색의 새 시간은 $base_i + (\text{old_search_time} - \text{session_origin})$ 으로 계산한다. SEARCH·EVENT $session_end_time$ 에 동일한 이동량을 적용하여 내부 및 교차 스트림 상대시간을 보존한다.
9. 검색 내용($query_text$, 목적지, 체크인·체크아웃, 결과 수, 정렬, 인원 등)은 원본 세션 값을 복제한다.
10. $search_id$ 와 $session_id$ 는 합성 키로 치환하고 $data_origin='synthetic_augmentation'$ 으로 설정한다.

```
new_search_time = base_time_i + (old_search_time - min_search_time_of_source_session)
```

11. 3.8 숙박일 역전 보정

먼저 원본 SEARCH 전체에서 checkout_date-checkin_date 가 1 일 이상인 정상 숙박기간을 일수 목록 valid_durations 로 만든다. 복제 대상 검색에서 checkout_date≤checkin_date 이면 고정 RNG 로 valid_durations 중 하나를 선택해 checkout_date=checkin_date+선택 일수로 바꾼다.

```
valid_durations = [(checkout - checkin).days for 모든 원본 검색 if days > 0]
if copied_checkout <= copied_checkin:
    copied_checkout = copied_checkin + RNG.choice(valid_durations) days
```

주의: config 에는 '같은 원본 세션에서 정상 기간을 뽑는다고 적혀 있지만 승인 생성 코드의 실제 구현은 원본 전체 정상 숙박기간 풀을 사용한다. 완전 재현 시에는 실제 코드와 동일하게 전체 풀을 사용해야 현재 승인 DB 와 일치한다. 향후 생성기 개정 시 config 와 코드를 일치시키는 별도 결정이 필요하다.

12. 3.9 SEARCH_FILTER 와 SEARCH_RESULT 복제

- SEARCH_FILTER: old_search_id 에 해당하는 단일 행을 찾아 필터 값을 그대로 복제한다. 새 search_filter_id 와 new_search_id 를 기록하고 old_filter_id→new_filter_id 매핑을 보관한다.
- SEARCH_RESULT: old_search_id 의 결과를 result_rank 순으로 정렬한다. hotel_id, room_id, result_score, result_rank, price_rank 는 유지하고 search_result_id 와 search_id 만 새 키로 바꾼다.
- 각 복제 검색의 SEARCH_RESULT 행 수가 해당 SEARCHtotal_result_count 와 같아야 한다.

13. 3.10 EVENT 복제와 제외 순서

11. 원본 세션 EVENT 는 event_at, event_id 로 안정 정렬하되, SEARCH 와 공통인 session_origin 을 사용한다.
12. booking_start, booking_complete, booking_cancel 이벤트는 복제하지 않는다.
13. hotel_click 또는 hotel_detail_view 이벤트의 hotel_id 가 새 검색의 SEARCH_RESULT 에 없으면 해당 이벤트를 복제하지 않는다.
14. 남은 이벤트의 event_id, session_id, user_id, search_id, search_filter_id 를 합성 키로 치환한다. 검색 필터 키가 없는 이벤트는 원본처럼 NULL 을 유지한다.
15. 새 event_at 은 base_i + (dd_event_at - session_origin), 새 session_end_time 은 base_i + (old_session_end_time - session_origin)으로 계산한다. jittering 과 로그정규 난수 생성은 적용하지 않는다.
16. event_type, hotel_id, rating, review 관련 값, device 등 나머지 필드는 유지하고 data_origin='synthetic_augmentation'으로 설정한다.

```
if event_type in booking event types: skip
if event_type in {hotel_click, hotel_detail_view} and (new_search_id, hotel_id) not in exposed_pairs: skip
new_event_at = base_time_i + (old_event_at - min_event_time_of_source_session)
```

14. 3.11 USER 와 BOOKING 처리

- 각 i 에 대해 합성 USER 1 행을 생성한다. signup_at 은 합성 기준시각 30 일 전, age_group 은 NULL, data_origin 은 synthetic_augmentation 이다.
- 생성 코드는 합성 사용자명, 이메일 placeholder 를 만들지만 실제 개인정보가 아니다. 그래도 보고 분석 산출물에서는 user_name 과 email 을 내보내지 않는다.
- BOOKING 은 테이블을 스키마만 만들고 어떤 행도 삽입하지 않는다. 원본 BOOKING 36 행도 복사하지 않는다.

15. 3.12 적재 순서, 메타데이터와 인덱스

참조 무결성을 고려해 HOTEL_ROOM 을 먼저 적재하고, 이후 USER, SEARCH, SEARCH_FILTER, SEARCH_RESULT, EVENT 를 적재한다. BOOKING 은 빈 상태로 둔다. _generation_metadata 에는 sample_set_type, scenario_id, random_seed, config_version, generation_version, n_users, n_sessions 를 JSON 문자열로 저장한다.

인덱스	컬럼	목적
idx_syn_search_session_time	SEARCH(session_id, search_time, search_id)	세션 내 안정 검색 정렬
idx_syn_result_search_hotel	SEARCH_RESULT(search_id, hotel_id)	노출 결과미노출 클릭 검사
idx_syn_event_search_hotel_type	EVENT(search_id, hotel_id, event_type)	검색별 행동 조회
idx_syn_event_session_type	EVENT(session_id, event_type)	세션별 행동 조회

표 해설 | 내 인덱스는 세션 정렬과 노출행동 조회를 빠르게 할 뿐 데이터 값이나 분석 의의를 바꾸지 않는다.

모든 행과 메타데이터 인덱스 생성이 끝난 뒤 한 번 commit 하고 연결을 닫는다. 중간 실패 시 불완전한 DB 를 승인 산출물로 사용하지 않는다.

16. 3.13 동일 생성 코드를 이용한 실행 명령

저장소 루트에서 아래 형식으로 실행한다. 출력 폴더는 반드시 새 빈 폴더로 지정한다. 승인 실행 묶음 폴더를 대상으로 다시 실행하거나 기존 SQLite 를 덮어쓰면 안 된다.

```
python "09_단계별
분석/2 단계_1000 건_중간_분석/02_관측형합성1000 명_실행묶음_260903_1606_01/호텔검색_관측형합성 1000 명_생성코드_260903_1606_01.py" --
db "travel_data_filtered_complete_2026-09-03_v02_비식별.sqlite" --config "09_단계별
분석/2 단계_1000 건_중간_분석/02_관측형합성1000 명_실행묶음_260903_1606_01/호텔검색_관측형합성 1000 명_생성설정_260903_1606_01.json"
--output-dir "<새로운_빈_출력폴더>"
```

코드는 설정의 stage2_bundle_run_id 에서 260903_1606 을 읽어 호텔검색_관측형합성 1000 명_데이터_260903_1606_01.sqlite 라는 이름을 만든다. 같은 파일이 있으면 FileExistsError 로 중단하는 것이 정상 동작이다.

17. 3.14 생성 직후 필수 QA 와 승인 기준

검사	합격 기준
SQLite	PRAGMA integrity_check='ok'
규모	USER 1,000; 세션 1,000; SEARCH 6,900; SEARCH_FILTER 6,900; SEARCH_RESULT 198,128; EVENT 238,851; BOOKING 0
기준정보 검색필터	HOTEL 1,000; ROOM 3,000 SEARCH 와 SEARCH_FILTER 가 search_id 기준 1:1
결과 수	SUM(SEARCH\$total_result_count)=SEARCH_RESULT 행 수=198,128
중복 결과	(search_id, hotel_id) 중복 0 건
호텔 연결 숙박일	SEARCH_RESULT.hotel_id=ROOM.hotel_id 불일치 0 건 checkout_dates>checkin_date 0 건
0 건 행동	0 건 검색의 impression/dclick/detail 0 건
클릭 노출	검색 결과에 없는 hotel_click 0 건
행 출처	SEARCH 의 data_origin 이 모두 synthetic_augmentation
핵심 패턴	결과 없음 3,434/6,900, 0 건 후 후속검색 3,271/3,434 즉시 회복 558/3,271, 세션 최종 회복 488/651, hotel_click 1,052/6,900

표 해설 | 이 표의 모든 조건을 통과해야 생성물을 승인할 수 있다. 불일치가 나면 seed 를 바꾸지 말고 해시→정렬→키 매핑→제외 규칙 순으로 원인을 찾는다.

위 값은 seed=20260903 과 승인 코드 설정 원본 해시가 모두 같을 때의 재현 기준이다. 값이 다르면 seed 를 바꾸거나 결과를 덮어쓰지 말고 원본 해시, 세션 정렬, 키 매핑, 이벤트 제외, 숙박일 보정, 패키지 버전을 순서대로 점검한다.

18. 3.15 구현용 의사코드


```

open source DB read-only
create empty destination schema
copy HOTEL and ROOM exactly
load original SEARCH, FILTER, RESULT, EVENT
create valid stay-duration pool
choose 1,000 source sessions using 23 balanced copies + 11 seeded extras
shuffle chosen sessions with seed 20260903
for i, source_session in chosen_sessions:
    create synthetic USER and SESSION IDs
    set deterministic base time
    for each ordered SEARCH j:
        map old search/filter IDs to new IDs
        shift search time; repair reversed stay date if needed
        copy one FILTER and all ranked RESULTS
    build exposed (new_search_id, hotel_id) set
    for each ordered EVENT k:
        skip booking events
        skip click/detail if hotel was not exposed
        map keys and shift event/session-end times
insert USER, SEARCH, FILTER, RESULT, EVENT
leave BOOKING empty
write generation metadata and four indexes
commit, close, run all QA, calculate SHA-256

```

목차와 표 해설 가독성 보완 완료

4. 합성 SQLite 테이블 구조와 데이터 사전

합성 SQLite에는 원본과 같은 8개 업무 테이블과 생성 계보를 위한 _generation_metadata 테이블이 있다. 아래 행 수는 승인된 S0 합성 DB의 실제 값이다.

테이블	행 수	데이터 성격	역할	PK	핵심 처리
USER	1000	합성	합성 사용자, 사용자 세션 1:1	user_id	보고서에 user_name,email 미 포함
HOTEL	1000	원본 기준정보 복사	호텔 마스터	hotel_id	행 값 등장 없음
ROOM	3000	원본 기준정보 복사	객실 상품/타입 마스터	room_id	틀리 재고로 해석하지 않음
SEARCH	6900	합성	검색 사실 및 결과 수	search_id	session_id 로 1,000 세션
SEARCH_FILTER	6900	합성	검색별 필터 조건	search_filter_id	SEARCH 와 search_id 1:1
SEARCH_RESULT	198128	합성	검색 노출 결과	search_result_id	합계=SEARCH 결과 수 합계
EVENT	238851	합성	검색 노출 클릭 행동	event_id	예약 이벤트와 미노출 클릭 제외
BOOKING	0	빈 스키마	예약 정보	booking_id	예약전환 분석 제외
_generation_metadata	7	생성 메타데이터	시나리오 seed 버전 규모	key	업무 KPI 에 사용하지 않음

표 해설 | 행 수 옆은 실제 합성 DB 규모다. HOTEL-ROOM 만 원본 기준정보이고 USER-SEARCH-FILTER-RESULT-EVENT 는 합성 행이며 BOOKING 은 빈 스키마다.

19. 4.1 테이블별 정확한 컬럼 목록

테이블	컬럼(실제 SQLite 컬럼명)
USER	user_id, user_name, age_group, email, signup_at, data_origin
HOTEL	hotel_id, hotel_name, city_name, grade, hotel_address, user_rating, review_count, property_type, actual_address, actual_city, actual_prefecture, actual_postal_code, actual_latitude, actual_longitude, actual_phone, actual_star_rating, supplier_hotel_code, rtx_code, agoda_code, expedia_code, top_selling_rank, source_last_mapped_at, actual_data_sources, data_origin

테이블	컬럼(실제 SQLite 컬럼명)
ROOM	room_id, hotel_id, guest_count, room_count, room_options, pay_later_flag, free_cancel_flag, room_price, room_type, data_origin
SEARCH	search_id, session_id, search_time, query_text, checkin_date, checkout_date, total_result_count, sort_option, guest_count, destination, data_origin
SEARCH_FILTER	search_filter_id, search_id, property_type, property_grade, user_rating_min, price, amenity_count, region, data_origin
SEARCH_RESULT	search_result_id, search_id, hotel_id, room_id, result_score, result_rank, price_rank, data_origin
EVENT	event_id, session_id, event_type, event_at, hotel_id, search_filter_id, search_id, user_id, rating, session_end_time, review_completed_at, review_text, device, data_origin
BOOKING	booking_id, user_id, hotel_id, room_id, booking_status, booking_amount, booking_at, checkin_date, checkout_date, guest_count, room_count, cancellation_deadline, data_origin
_generation_metadata	key, value

표 해설 | 컬럼명은 실제 SQLite 이름 그대로다. 구현할 때 임의 별칭을 쓰더라도 최종 적재 시 이 이름과 데이터형을 유지해야 기존 분석 코드가 작동한다.

20. 4.2 주요 관계와 분석 사용 범위

관계	카디널리티	사용 범위
USER → SEARCH/EVENT	user_id 및 합성 세션 연결	개인정보 유훈은 분석 산출물에서 제외
SEARCH → SEARCH_FILTER	search_id 기준 1:1	A1-A2 필터 및 의도 분류
SEARCH → SEARCH_RESULT	search_id 기준 1:N	결과 수 노출 무결성
SEARCH → EVENT	search_id 기준 1:N	hotel_click 존재 여부와 행동 플래그
HOTEL → ROOM	hotel_id 기준 1:N	호텔 객실 상품 기준정보
SEARCH_RESULT → HOTEL/ROOM	hotel_id, room_id	노출 결과의 호텔 객실 연결
BOOKING → USER/HOTEL/ROOM	스키마상 키만 존재, 현재 0 행	성과 KPI와 가설검정에서 제외

표 해설 | SEARCH-FILTER는 1:1, SEARCH-RESULT와 SEARCH-EVENT는 1:N이다. 조인 시 SEARCH_RESULT와 EVENT를 동시에 붙이면 행이 곱해질 수 있으므로 각각 집계한 뒤 결합한다.

21. 4.3 증강 데이터 해석 시 주의

- 이 DB는 '원본 296 검색 + 추가 합성 검색'의 합본이 아니다. 행동 데이터는 합성 행만 들어 있으며 HOTEL-ROOM 기준정보만 원본에서 복사됐다.
- 원본의 사용자 89명, 검색 296건, BOOKING 36건은 별도 원본 DB에 남아 있다.
- S0 1,000명이라는 표현은 합성 사용자 1,000개를 뜻한다. 실제 모집된 사용자 1,000명의 관측 결과가 아니다.
- 실제 가설 판단은 원본 296검색을 기준으로 하고, 합성 분석은 생성기와 분석 파이프라인의 구조 방향 보존을 확인하는 용도다.

5. 데이터 계보·품질·재현성 QA

5.1 STEP R2.5 권위 입력과 계보

최종 분석 입력은 lineage 가 제거된 시간축 보정 관측형 합성 1,000 명 승인 DB 로 고정했다. 수정 전 S0 는 비교 기준으로 보존하고, R1 lineage 포함 DB 는 QA 전용으로만 사용했다. 승인 DB SHA-256 은 7d449fab6847730be38fe46ebb6bd6a5b31690cdf38cf4bdbadeaa75edd1ae04 이다.

STEP1-STEP2-STEP3 는 모두 새 입력 해시에 근거해 재실행했으며 전체 불일치 건수는 0 건이다.

5.2 고차 조건부 결합확률(High-order Interaction) 검증

분석 단위는 SEARCH 1 행이다. 실제 선택형 필터 3 개(price IS NOT NULL, user_rating_min IS NOT NULL, amenity_count > 0)가 모두 활성화된 검색을 고차 중첩으로, total_result_count=0 을 결과 없음으로 정의한다. 정의 B 에서 가능한 3 필터 조합은 price+rating+amenity 하나뿐이며 복수의 주요 조합이 존재하는 것으로 해석하지 않는다.

제한 Bayesian Network 고차검증은 지역, 검색 의도, 가격·평점·편의시설 활성 플래그, active_filter_count, zero_result 를 사용하는 제한 범주형 Naive Bayes/제한 DAG 진단이다. 라플라스 평활을 적용하고 원본 세션 템플릿 fingerprint 기준 5-fold GroupKFold 로 분리했으며, 승인 합성본도 같은 fingerprint 그룹을 사용했다. train/test fingerprint 누출은 0 이고 세션 단위 bootstrap 500 회를 사용했다.

BN 은 조건부 구조 보존 진단이며 인과 검증 용도가 아니다. 합성 표본의 한계상 작은 p 값이나 유사한 성능을 실제 모집단에 대한 증거 강화로 해석하지 않는다.

본 분석의 고차 결합은 price IS NOT NULL, user_rating_min IS NOT NULL, amenity_count > 0 의 3 개 선택형 필터로 정의했다. region 은 destination 과 동일하여 필터 수에서 제외하고 BN 지역 설명변수만으로 사용했으며, property_type 과 property_grade 는 전 행 NULL 이므로 제외했다.

구분	분자	분모	비율	원본 대비
원본	91	104	87.5000%	기준
시간축 보정 승인 합성본	2,125	2,425	87.6289%	+0.1289%p

제한 BN 결과

구분	Log loss	Brier	ROC-AUC	ECE
원본	0.942203	0.191710	0.823106	0.173780
시간축 보정 승인 합성본	0.915162	0.182365	0.832769	0.151952

고차 결합 본 분석과 제한 BN 은 조건부 구조가 대체로 보존되었음을 보여준다. 이는 모집단 대표성이나 인과효과를 뜻하지 않으며, ECE 가 0 이 아니므로 완전 보정으로 해석하지 않는다. 고차 결합 판정은 PASS 이다. 6 개 플래그 정의 A 는 민감도 분석으로만 보관하며 원본 119/160(74.3750%), 승인 합성본 2,783/3,741(74.3919%)이다.




그림. 고차 결합 및 제한 BN 비교(R2.5 권위 산출물)

5.3 세션 시계열 간격(Inter-arrival Time) 현실성 검증

세션별 SEARCH 를 search_time, search_id 로 안정 정렬한 뒤, 현재 검색이 0 건이고 동일 세션에 바로 다음 검색이 존재할 때 두 SEARCH 의 시간차를 인접 전이의 Inter-arrival Time 으로 정의한다. 0 초는 역전이 아니지만 로그 변환과 로그정규 적합에서는 제외하며, 음수 간격은 시계열 역전으로 판정한다.

검증 결과는 원본 경험 시간차 보존=PASS 이다. 다만 모수 재추정 parametric bootstrap 에서 로그정규 적합성은 지지되지 않음(WARN)이며, 현실적 체류시간의 입증으로 해석하지 않는다. 승인 합성본은 로그정규분포에서 새 시간을 생성하지 않았고 Jittering 도 적용하지 않았다.

구분	n	음수	0 초	양수	평균	중앙값	Q1-Q3	P90	P95	최대
실제 관측 원본	140	0	1	139	17.7214 초	12 초	7-18 초	31.1 초	39.1 초	249 초
시간축 보정 승인 합성본	3,271	0	23	3,248	17.7447 초	12 초	7-18 초	32 초	40 초	249 초

양수 간격에 로그정규분포를 적합하고 모수를 재추정하는 parametric bootstrap 을 적용했다. 원본은 $\mu=2.507199$, $\sigma=0.730609$, $p=0.019960$, 승인 합성본은 $\mu=2.507799$, $\sigma=0.730905$, $p=0.001996$ 이다. 두 자료 모두 5% 유의수준에서 로그정규 적합이 지지되지 않아 WARN 을 유지한다. 이번 생성은 jittering 이나 로그정규분포 생성을 적용하지 않았고 원본의 시간차를 보존한 것이다.

5.4 시간 일관성과 교차 스트림

공통 시간 원점으로 교차 스트림 오류 수정: `session_origin=min(유효 SEARCH.search_time, 실제 복제 대상 EVENT.event_at)`을 세션마다 하나만 정의하고 `SEARCH-EVENT-session_end_time`에 동일한 이동량을 적용했다. `SEARCH-EVENT` 원본 상대시간 불일치는 0 건, 최대 오차는 0 초이다. `EVENT` 원천 순번은 `NOT_TESTABLE`이며 원천 전체 순서에 대한 검증 주장은 하지 않는다.

검사 항목	결과	판정
SEARCH 내부 음수 간격	0	PASS
EVENT 내부 음수 간격	0	PASS
SEARCH-EVENT 상대시간 불일치 / 최대 오차	0 / 0 초	PASS
click 보다 이른 detail view	0	PASS
session_end_time 역전	0	PASS
EVENT source ordinal	원천 순번 미제공	NOT_TESTABLE

교차 스트림 중첩 비교

데이터	중첩	비교 가능 건	중첩률
원본	64	7,210	0.8877%
수정 전 기존 S0	148,529	167,330	88.7641%
시간축 보정 승인 합성본	1,474	167,330	0.8809%

공통 `session_origin`을 `SEARCH`와 `EVENT`에 동일하게 적용해 원본 교차 스트림 상대시간을 복원했다. 전체 시간 검증은 구조·순서·상대시간 항목은 PASS 이나 로그정규 적합성 WARN 을 포함하므로 **CONDITIONAL PASS**이다.




그림. 시간 간격 및 교차 스트림 비교(R2.5 권위 산출물)

5.5 핵심 지표 및 STEP3 독립검수

지표	결과
전체 0 건률	3,434/6,900 (49.7681%)
0 건 후 후속검색률	3,271/3,434 (95.2533%)
즉시 회복률	558/3,271 (17.0590%)
세션 최종 회복률	488/651 (74.9616%)
상세진입률	1,052/6,900 (15.2464%)
세션 4 개 세그먼트	직접 성공 630 / 결과 노출·미선택 231 / 재검색 회복 92 / 지속 실패 47

기존 승인 STEP2 표를 새 승인 DB 에서 전수 재계산한 결과 불일치 0 건이었다. STEP3 는 STEP2 계산 함수와 결과 객체를 재사용하지 않는 독립 코드로 검수했으며 결정적 표본 44 건 중 실패 0 건, 전체 검수 불일치 0 건, 입력 불변성 및 개인정보 미출력을 확인했다.

단계	상태	역할
STEP1	PASS	승인 컨텍스트·해시 정규화 게이트
STEP2	PASS	전체 가설 계산·assertion 288 건
STEP3	PASS	독립 재계산·전수 대조·표본 추적 44 건

표 해설 | STEP1 은 입력·해시, STEP2 는 계산, STEP3 는 독립 재검산을 담당한다. 세 단계가 모두 PASS 여야 이 보고서의 수치를 사용할 수 있다.

생성 코드와 config 는 Git 전송 과정의 CRLF 차이만 확인됐으며, CRLF 를 LF 로 정규화한 SHA-256 이 부모 승인 해시와 일치하는 CRLF_TO_LF_ONLY 동등성으로 승인됐다. 두 파일은 이 단계에서 실행하거나 수정하지 않았다.

22. 5.1 지표 사전과 분석 단위

- A1-A2B1: 검색 단위, 반복 검색의 세션 내 상관으로 Fisher 검정의 독립성 한계가 있다.
- B2:세션 결과: 세션 단위.
- B3_IMMEDIATE_RECOVERY: 바로 다음 검색이 있는 0 건 전이 단위.
- B3_SESSION_FINAL_RECOVERY: 0 건 경험 세션 중 해당 0 건 이후 비 0 건이 발생한 세션.
- DIAG_FIRST_SEARCH_ZERO_RECOVERY: 첫 검색 0 건 세션만 대상으로 한 별도 진단지표.
- H3: 0 건 검색에서 같은 세션의 바로 다음 검색으로 이어지는 전이 단위.
- 상세진입 KPI 는 hotel_click 하나만 사용하며 hotel_detail_view 를 별도 성과로 합산하지 않는다.

23. 5.2 계산 및 독립 검수 결과

STEP2 assertion 288 건과 STEP3 전수 대조가 모두 PASS 였다. 계산 불일치 0 건, 중복 키 0 건, 누락·추가 집계행 0 건, B3 정의 혼용 없음으로 확인됐다.

STEP2 Excel 에는 검색전이 단위 분류행이 저장되지 않아 동일 개별 ID 끼리의 직접 대조는 불가능했다. 대신 독립 표본 추적, 집계표 전수 일치, STEP2 코드 정적 검토를 결합해 분류 로직을 확인했다.

24. 5.3 문서 QA 상태

document_visual_qa=STRUCTURAL_ONLY / MANUAL_VISUAL_REVIEW_REQUIRED. Microsoft Word 자동 렌더러가 HRESULT 0x800A13E9 로 문서를 열지 못해 전 페이지 시각 검증을 완료하지 못했다. DOCX 재열기, ZIP:OOXML 관계 표·문단 및 내장 이미지 6 개 검사는 통과했다. 이 제한은 분석 파이프라인의 확장 가능 여부와 분리한다.

6. 가설 검증 개요

이 장은 가설 코드를 먼저 외워야 하는 방식이 아니라, '무엇을 예상했고 어떤 데이터와 계산으로 확인했는가'를 순서대로 설명한다. 가설 판정은 실제 관측 원본 296 검색을 기준으로 하며, S0 1,000 명 결과는 생성 규칙과 분석 파이프라인이 원본의 핵심 구조를 재현하는지 확인하는 내부 진단값이다.

가설	가설의 뜻	분석 단위	핵심 비교-분모	검증 방법	최종 해석
A1	제한적 필터일수록 0 건 검색이 많다	검색	필터 제한/설정군 vs 비교군	2x2 Fisher-OR 95% CI	부분 채택
A2	지역 검색의도에 따라 0 건률이 다르다	검색	지역 6 개×의도 5 개	n-분자-분모 비율 기술통계	탐색적 기술통계
B1	0 건 검색은 다음 검색으로 더 자주 이어진다	검색	0 건 vs 비 0 건의 next 존재	2x2 Fisher-OR	관련성 확인, 비인과
B2	0 건 경험 세션은 검색 횟수가 많다	세션	0 건 경험 vs 미경험	Mann-Whitney U-효과크기	진단 결과, 비인과
B3	0 건 이후 즉시-세션 수준 회복이 발생한다	전이/세션	서로 다른 명시적 분모	분자+분모, 검정 없음	정의별 별도 보고
H3	재검색 변경 유형별 회복<click>률이 다르다	0 건 전이	6 개 전이 유형	유형별 성공률=hotel_click률	탐색적, 인과 아님

표 해설 | A1B1은 범주형 비율 비교, B2는 세션 검색 횟수의 순위 비교, A2B3H3는 정의된 분모별 기술통계로 검증한다. 동일 세션의 반복 검색과 자기선택 가능성이 있으므로 통계적 관련성을 제품 기능의 인과효과로 바꾸어 해석하지 않는다.

- 실제 가설 판정은 원본 296 검색43 세션의 관측 결과에 근거한다.
- S0 합성 모형은 사용자세션 각 1,000 개와 검색 6900 건으로, 생성기분석 파이프라인 및 모형 내부 패턴 보존을 확인하는 자료다.
- A1 부분 채택, A2 기술통계, B1 관련성, B2 비인과 진단, B3 단위 분리, H3 탐색적 결과를 유지한다.
- STEP2 assertion 288 건과 STEP3 독립 재검산을 통과했다. 계산 불일치-중복누락은 0 건이다.
- 다음 10,000 명 확장 집입은 허용되지만 이는 실제 사용자 10,000 명의 관측자료가 아니다.

데이터 역할	자료	분자/분모	비율
실제 관측 원본	결과 없음률	147/296	49.66%
S0 합성 모형 1,000 명	결과 없음률	3,434/6,900	49.77%
실제 관측 원본	0 건 후 후속검색률	140/147	95.24%
S0 합성 모형 1,000 명	0 건 후 후속검색률	3,271/3,434	95.25%
실제 관측 원본	즉시 회복률	24/140	17.14%
S0 합성 모형 1,000 명	즉시 회복률	558/3,271	17.06%
실제 관측 원본	세션 최종 회복률	21/28	75.00%
S0 합성 모형 1,000 명	세션 최종 회복률	488/651	74.96%
실제 관측 원본	hotel_click률	45/296	15.20%
S0 합성 모형 1,000 명	hotel_click률	1,052/6,900	15.25%
실제 관측 원본	첫 검색 0건 세션 회복률	4/6	66.67%
S0 합성 모형 1,000 명	첫 검색 0건 세션 회복률	92/139	66.19%

표 해설 | 같은 지표를 실제 관측 원본과 S0 합성 모형으로 나란히 제시한다. 두 값이 가깝다는 것은 생성 구조가 핵심 비율을 재현했다는 뜻이지, 합성 데이터가 새로운 실증 근거라는 뜻은 아니다.

표 1. 승인된 핵심 지표 6개

25. 6.1 원본과 S0 합성 1,000 명 비교

핵심 지표의 원본-합성 차이는 작고 A1-B1 방향도 보존됐다. 세부 지역×의도 및 H3 유형 분포는 표본과 생성 규칙에 따라 차이가 있을 수 있다. S0 결과는 생성기 분석 코드 검증과 후속 파이프라인 점검에 사용할 수 있지만 실제 시장 규모나 실제 사용자 효과 추정에는 사용할 수 없다.

6.1 A1 — 제한적 필터일수록 결과 없음률이 높다

가설과 분석 방법 | A1-1은 amenity_count ≥ 3 대 < 3, A1-2는 user_rating_min 설정 대 미설정, A1-3은 price 설정 대 미설정을 비교한다. search 와 search_filter 를 search_id 로 1:1 결합한 검색 1 건을 분석 단위로 삼고 total_result_count=0 을 결과 없음으로 코딩한다. 각 비교마다 [제한/설정군의 0 건·비 0 건, 비교군의 0 건·비 0 건] 2×2 표를 만든 뒤 양측 Fisher exact 검정, 제한/설정군+비교군 오즈비(OR), log(OR) Wald 95% CI 를 계산한다. 0 셀이 있을 때 CI 에만 0.5 보정을 적용하고 Fisher 검정은 원자료 표를 사용한다. 원본 결과는 각각 120/136 대 27/160, 115/152 대 32/144, 106/146 대 41/150 이며 모두 제한/설정군의 0 건률이 높다. 다만 입력 상태를 구분할 컬럼이 없어 조건 제한 효과와 입력 품질 효과를 분리하지 못했으므로 최종 판정은 부분 채택이다.

데이터	비교	제한집단	0 건	비율	OR	95% CI	Fisher p
실제 관측 원본	편의시설	amenity_count ≥ 3	120/136	88.2%	36.94	[18.98, 71.90]	2.17e-37
S0 합성 모형 1,000 명	편의시설	amenity_count ≥ 3	2808/3181	88.3%	37.20	[32.40, 42.70]	0
실제 관측 원본	최소평점	set	115/152	75.7%	10.88	[6.34, 18.67]	7.16e-21
S0 합성 모형 1,000 명	최소평점	set	2695/3558	75.7%	11.00	[9.83, 12.30]	0
실제 관측 원본	가격	set	106/146	72.6%	7.05	[4.23, 11.75]	5.8e-15
S0 합성 모형 1,000 명	가격	set	2473/3408	72.6%	6.97	[6.27, 7.74]	3.04e-317

표 해설 | 제한 또는 설정 집단의 결과 없음 오즈를 비교집단과 비교한다. 원본에서 OR 이 모두 1 보다 크지만, 입력 상태 컬럼 부재 때문에 A1 은 부분 채택으로 제한한다.

표 2 A1 필터 비교 (OR 은 제한/설정 집단 + 비교집단)




그림 1. A1 필터별 결과 없음률

그래프 해설 | 파란 막대는 실제 관측 원본, 주황 막대는 S0 합성 모형이다. 편의시설 3 개 이상 최소평점 설정·가격 설정 집단에서 결과 없음률이 비교집단보다 높다. 두 데이터의 막대 높이가 비슷한 것은 방향 재현을 뜻하며, 합성 결과가 새로운 실제 효과를 입증하는 것은 아니다.

원본 A1 은 부분 채택한다. 다만 입력 상태를 구분할 컬럼이 없어 조건 제한 효과와 입력 품질 효과를 분리하지 못했다. 합성 결과는 방향 보존을 확인하는 모형 내부 진단이다.

6.2 A2 — 지역·검색의도별 결과 없음률이 다르다

가설과 분석 방법 | 검색 단위에서 지역 Tokyo-Osaka-Kyoto-Sapporo-Fukuoka-UNKNOWN 과 의도

LOCATION_ONLYPRICE-QUALITY_FILTERAMENITY-MIXED 를 기존 코드북대로 분류한다. 6×5 의 전체 격자를 만든 뒤 각 셀에 검색 수 n , 0 건 수(분자), 전체 검색 수(분모), 0 건률을 계산한다. $n=0$ 은 0%가 아니라 N/A 로 표시하고 $n<5$ 와 $n<10$ 을 최소 셀로 경고한다. 표본이 작은 셀이 있으므로 우열 검정이나 인과 판정을 하지 않고 기술통계로만 확인한다. 따라서 A2 는 '차이가 관찰됨' 수준의 탐색적 결과다.

지역 6 개×검색의도 5 개의 30 개 셀을 데이터셋별로 유지했다. 각 셀에 n 과 결과 없음률을 표시했으며 $n=0$ 은 N/A(미관측)로 구분했다. 최소 셀은 우열이나 인과로 해석하지 않는다.



그림 2. A2 지역×검색의도 결과 없음률

그래프 해설 | 색이 진할수록 결과 없음률이 높고 각 셀의 n 이 표본 크기다. 먼저 n 을 확인한 뒤 비율을 읽어야 한다. N/A 는 해당 조합이 관측되지 않았다는 뜻이며 0%나 불가능을 뜻하지 않는다. 원본의 작은 n 셀은 기술통계로만 본다.

6.3 B1 — 결과 0 건 검색은 바로 다음 검색으로 더 자주 이어진다

가설과 분석 방법 | 모든 검색을 session_id 안에서 파싱한 search_time, search_id 순으로 안정 정렬한다. 같은 세션의 바로 다음 행이 있을 때 next_search_exists=1 로 정의한다. 현재 검색의 0 건 여부(0 건/비 0 건)와 다음 검색 존재 여부(있음/없음)의 2×2 표를 만들고 양측 Fisher exact 검정과 0 건군+비 0 건군 OR 을 계산한다. 원본은 0 건 후 140/147, 비 0 건 후 113/149 로 OR 6.37, $p \approx 1.81 \times 10^{-6}$ 이다. 이는 후속검색과의 관련성이지 결과 없음이 재검색을 유발했다는 인과 증거는 아니다.

데이터	집단	후속검색	비율	OR	95% CI	Fisher p
실제 관측 원본	0 건	140/147	95.24%	6.37	[2.73, 14.86]	1.81e-06
실제 관측 원본	비 0 건	113/149	75.84%	6.37	[2.73, 14.86]	1.81e-06
S0 합성 모형 1,000 명	0 건	3271/3434	95.25%	6.39	[5.36, 7.61]	4.05e-125
S0 합성 모형 1,000 명	비 0 건	2629/3466	75.85%	6.39	[5.36, 7.61]	4.05e-125

표 해설 | 0건 검색은 비 0건 검색보다 바로 다음 검색으로 이어진 비율이 높다. 이는 재검색과의 관련성이지만 0건이 재검색을 일으켰다는 인과 증거는 아니다.




그림 3 B1 후속검색률

그래프 해설 | 0건 검색 뒤에는 원본 140/147, 합성 3,271/3,434 에서 바로 다음 검색이 있었다. 비 0건 검색보다 후속검색률이 높지만 이는 관련성이다. 동일 세션 반복 검색의 상관과 사용자의 탐색 의지가 함께 영향을 줄 수 있다.

0건 여부와 후속검색 존재 간 관련성을 보여주지만 인과효과는 아니다.

6.4 B2 — 0 건 경험 세션은 검색을 더 오래 지속한다

가설과 분석 방법 | 세션별로 검색 수를 세고 세션 내 total_result_count=0 이 한 번이라도 있으면 0 건 경험군, 없으면 미경험군으로 나눈다. 두 군의 n-평균중앙값IQR 을 제시하고 분포 정규성을 가정하지 않는 양측 Mann-Whitney U(method=auto)를 적용한다. IQR 은 pandas 선형 순위수, rank-biserial 은 양수일수록 0 건 경험군의 검색 수가 큰 방향으로 계산한다. 원본은 28 세션 대 15 세션, 평균 9.00 대 2.93 이며 $U=382$, $p \approx 1.12 \times 10^{-5}$ 이다. 오래 탐색한 세션일수록 0 건을 경험할 기회도 커지는 탐색지속성 교란 때문에 비인과 진단으로만 해석한다.

데이터	세션 집단	n	평균	중앙값	Q1-Q3	U	p	rank-biserial
실제 관측 원본	0 건 경험	28	9.00	7.00	5.00-10.25	382.0	1.12e-05	0.819
실제 관측 원본	0 건 미경험	15	2.93	2.00	1.50-3.00	382.0	1.12e-05	0.819
S0 합성 모형 1,000 명	0 건 경험	651	9.03	7.00	5.00-11.00	206867.0	6.87e-103	0.821
S0 합성 모형 1,000 명	0 건 미경험	349	2.93	2.00	1.00-3.00	206867.0	6.87e-103	0.821

표 해설 | 0 건 경험 세션의 검색 횟수가 더 많지만, 오래 탐색한 세션일수록 0 건을 경험할 기회도 늘어난다. 따라서 U 검정과 효과크기는 탐색지속성 진단으로 읽는다.

B2 는 탐색지속성이 높은 사용자가 0 건과 많은 검색을 함께 경험했을 가능성이 있어 비인과 진단으로만 해석한다.

6.5 B3 — 결과 없음 이후 후속 검색에서 회복이 발생한다

가설과 분석 방법 | 서로 다른 질문을 하나의 회복률로 합치지 않는다. B3_IMMEDIATE_RECOVERY 는 '바로 다음 검색이 있는 0 건 검색' 140 건 중 next 결과가 비 0 건인 24 건(17.14%)이다. B3_SESSION_FINAL_RECOVERY 는 '세션 중 한 번이라도 0 건을 경험한 세션' 28 개 중 그 0 건 이후 언젠가 비 0 건 검색이 나온 21 개(75.00%)다. DIAG_FIRST_SEARCH_ZERO_RECOVERY 는 첫 검색이 0 건인 6 세션 중 이후 비 0 건이 나온 4 세션(66.67%)인 별도 진단지표다. 각각 zero-transition-세션첫 검색 0 건 세션이라는 다른 분석 단위와 분모를 사용하며 추론검정 없이 분자/분모와 비율을 보고한다.

데이터 역할	지표	분자/분모	비율
실제 관측 원본	즉시 회복률	24/140	17.14%
S0 합성 모형 1,000 명	즉시 회복률	558/3271	17.06%
실제 관측 원본	세션 최종 회복률	21/28	75.00%
S0 합성 모형 1,000 명	세션 최종 회복률	488/651	74.96%
실제 관측 원본	첫 검색 0 건 세션 회복률	4/6	66.67%
S0 합성 모형 1,000 명	첫 검색 0 건 세션 회복률	92/139	66.19%

표 해설 | 즉시 회복, 세션 최종 회복, 첫 검색 0 건 회복은 분모가 서로 다르다. 특히 21/28 과 4/6 을 같은 지표로 혼동하지 않아야 한다.




그림 4. B3 회복 지표와 서로 다른 분모

그래프 해설 | 세 막대 묶음은 서로 다른 질문이다. 즉시 회복은 0 건→다음 검색 전이, 세션 최종 회복은 0 건 경험 세션, 첫 검색 0 건 회복은 별도 진단 세션이 분모다. 따라서 17.1%, 75.0%, 66.7%를 한 순위로 직접 비교하면 안 된다.

즉시 회복, 0 건 경험 세션의 최종 회복, 첫 검색 0 건 세션의 별도 진단은 분석 단위와 분모가 다르며 합치지 않았다.

6.6 H3 — 재검색 방식별 다음 검색 성공률·상세진입률이 다르다

가설과 분석 방법 | 단위는 0 건 검색에서 같은 세션의 바로 다음 검색으로 이어진 zero-transition 이다. 문자열은 NFKC→trim→casefold 로 정규화하고, 분류 우선순위는 완전 동일→동일 조건 반복, 위치 변경→지역 변경, 위치 동일→query_text 변경→검색어 수정, 나머지 필터 변화→조건 완화/강화/혼합이다. 가격 상한 증가·해제, 최소평점 감소·해제, amenity_count 감소는 완화이며 반대는 강화, 두 방향이 함께 있으면 혼합이다. H3-1은 유형별 다음 검색 비 0 건률, H3-2는 유형별 다음 검색 hotel_click 보유 검색률을 계산한다. hotel_click 은 이벤트 수가 아니라 search_id 별 1 회 이상 여부이며 hotel_detail_view 를 중복 KPI 로 더하지 않는다. 원본 회복률은 지역 변경 10/24, 검색어 수정 3/10, 조건 완화 11/41 이고, 상세진입률은 각각 3/24, 3/10, 8/41 이다. H3-3의 제품 인과효과와 H3-4의 예약 완료 효과는 입증하지 않으며 BOOKING 은 참고·무결성 점검만 한다.

데이터	전이 유형	n	성공	성공률	click	click 률
실제 관측 원본	동일조건 반복	53	0/53	0.0%	0/53	0.0%
실제 관측 원본	조건 완화	41	11/41	26.8%	8/41	19.5%
실제 관측 원본	검색어 수정	10	3/10	30.0%	3/10	30.0%
실제 관측 원본	지역 변경	24	10/24	41.7%	3/24	12.5%
실제 관측 원본	조건 강화	10	0/10	0.0%	0/10	0.0%
실제 관측 원본	혼합 변경	2	0/2	0.0%	0/2	0.0%
S0 합성 모형 1,000 명	동일조건 반복	1238	0/1238	0.0%	0/1238	0.0%
S0 합성 모형 1,000 명	조건 완화	959	256/959	26.7%	187/959	19.5%
S0 합성 모형 1,000 명	검색어 수정	234	69/234	29.5%	69/234	29.5%
S0 합성 모형 1,000 명	지역 변경	563	233/563	41.4%	70/563	12.4%
S0 합성 모형 1,000 명	조건 강화	231	0/231	0.0%	0/231	0.0%
S0 합성 모형 1,000 명	혼합 변경	46	0/46	0.0%	0/46	0.0%

표 해석 | 유형별 n 을 먼저 보고 성공률과 click 률을 해석한다. 원본의 혼합 변경처럼 n 이 매우 작은 셀은 순위나 효과를 일반화하지 않는다.




그림 6. H3 재검색 유형별 성공률과 hotel_click 률

그래프 해설 | 왼쪽은 다음 검색이 비 0 건이 된 비율, 오른쪽은 다음 검색에 hotel_click 이 있었던 비율이다. 유형별 막대 위 분자/분모를 함께 봐야 한다. 원본 지역 변경의 회복률이 높지만 작은 유형 표본과 탐색적 분류이므로 제품 효과로 단정하지 않는다.

원본 검색어 수정 회복은 $3/10=30.0\%$ 이다. H3 는 탐색적 비교이며 제품 개선의 인과효과를 입증하지 않는다.

7. 세션 결과 4 개 세그먼트(보조 분석)

데이터	세그먼트	세션 n	구성비
실제 관측 원본	직접 성공	27	62.79%
실제 관측 원본	결과 노출미선택	10	23.26%
실제 관측 원본	재검색 회복	4	9.30%
실제 관측 원본	지속 실패	2	4.65%
S0 합성 모형 1,000 명	직접 성공	630	63.00%
S0 합성 모형 1,000 명	결과 노출미선택	231	23.10%
S0 합성 모형 1,000 명	재검색 회복	92	9.20%
S0 합성 모형 1,000 명	지속 실패	47	4.70%

표 해설 | 네 세그먼트는 모든 세션을 정확히 한 번만 분류한다. 원본 43 세션과 합성 1,000 세션 모두 비율 구조가 유사하지만 합성값은 모형 내부 결과다.




그림 5. 상호배타 세션 결과 세그먼트

그래프 해설 | 모든 세션은 직접 성공결과 노출 미선택재검색 회복지속 실패 중 하나에만 속한다. 원본 43 세션과 합성 1,000 세션의 구성비가 유사해 세션 구조가 보존됐음을 보여준다. 합성 세션은 실제 모집 사용자가 아니다.

8. 종합 판정·해석 한계·다음 단계

8.1 R2.5 기반 종합 판정

검증 영역	판정	근거
STEP1 입력·해시·계보	PASS	승인 DB 해시 일치, lineage 제거 입력 고정
STEP2 전체 가설 및 보완 분석	PASS	기존 결과와 전수 비교 불일치 0
고차 결합 본 분석 및 제한 BN	PASS	주요 조건부 구조 보존
시간 순서·상대시간·교차 스트림	PASS	오류 0, 중첩률 원본 수준 복원
로그정규 적합성	WARN	원본·승인 합성본 모두 5% 수준에서 미지시
EVENT source ordinal	NOT_TESTABLE	원천 순번 미제공
STEP3 독립검수	PASS	결정적 표본 실패 0/44, 전체 불일치 0
보고서 개정	PASS	R2.5 권위 산출물과 계보 반영

STEP R3-A=PASS: R2.5 권위 산출물을 반영한 보고서 개정 초안이 생성되었으며, 다음 단계에서 독립 문서 QA를 수행할 수 있다.

8.2 변경 이력

2026-09-05 | STEP R3-A | 수정 전 S0 해시

db80db7048add9c0c4cb1a985e67a77ae99bef3a30ce32bedb70cc0ee61dc896 을 변경 이력에 보존했다. SEARCH/EVENT 분리 시간 원점 오류를 공통 session_origin 공식으로 교체하고, R2.5 승인 lineage 제거 DB 와 해시, 고차 결합 정의 B-정의 A 민감도 분석, 시간 간격·교차 스트림, STEP1-STEP2-STEP3 PASS 결과를 추가했다. 전체 불일치는 0 건이며 Jittering 은 적용하지 않았다. QA DB 와 분석·배포 DB 는 분리했다. 로그정규 적합성은 WARN 으로 유지했다. 기존 A1-A2-B1-B2-B3-H3 및 핵심 집계값은 변경하지 않았고 원본 보고서와 기존 산출물은 보존했다.

- 원본 표본은 296 검색·43 세션이며 탐색적 분석이다.
- 검색 단위 Fisher 검정은 동일 세션 반복 검색 때문에 독립성 한계가 있다.
- 합성 p 값은 모형 내부 진단이며 실제 증거를 강화하지 않는다.
- A1 은 입력 상태 구분 컬럼 부재의 한계가 있다.
- A2 회소 결과 0%는 해당 표본에서 미관측된 값이다.
- B2 에는 탐색지속성 교란 가능성이 있다.
- A3 는 제외했고 hotel_detail_view 를 별도 전환 KPI 로 사용하지 않았다.
- 합성 DB BOOKING 은 0 행이며 예약전환 분석에서 제외했다.

26. 12.1 10,000 명 확장 진입 판정

FINAL=PASS 이면 교정 매니페스트와 이번 분석 보완 매니페스트의 전체 SHA-256 및 승인 상태를 다시 확인한 뒤 S0 10,000 명 확장 프롬프트를 개정할 수 있다. 이번 단계에서는 10,000 명 데이터를 생성하거나 분석하지 않았다.

판정 항목	상태
generator_expansion_allowed	true
analysis_pipeline_ready_for_stage3	true
실제 10,000 명 생성	미실행

표 해설 | 두 승인 상태가 true 라는 것은 다음 확장 프롬프트를 준비할 수 있다는 뜻이다. 이번 보고서가 실제 10,000 명 효과를 입증했다는 의미는 아니다.